

Критерии оценки разработанного ИИ-агента для инструмента учебной аналитики

Ниже представлена система критериев, разделенная

на **функциональные, качественные, технические и пользовательские** группы.

Каждый критерий снабжен шкалой оценки (0–5 баллов) и описанием пороговых значений.

1. Функциональные критерии (соответствие ТЗ)

№	Критерий	Описание	Шкала оценки
1.1	Полнота обработки числовых данных	Агент корректно рассчитывает средние арифметические, медианы, стандартные отклонения, процентное распределение (1–3, 4–7, 8–10) по 4 критериям, а также общий уровень удовлетворенности	0 — не рассчитывает ничего / 5 — все расчеты выполнены верно
1.2	Полнота обработки текстовых данных	Агент обрабатывает 100% текстовых комментариев (19 открытых вопросов), проводит тематическое моделирование, сентимент-анализ, извлекает ключевые проблемы и цитаты с указанием частоты упоминания	0 — обрабатывает <30% / 5 — обрабатывает 100%
1.3	Структура аналитической справки	Агент формирует справку, содержащую все 4 обязательных раздела: 1) общая информация о программе; 2) ключевые критерии; 3) предложения слушателей; 4) траектория изменения программы	0 — отсутствует 2+ разделов / 5 — все разделы полностью заполнены
1.4	Формирование рекомендаций	Агент генерирует 3–7 обоснованных, логичных и действенных выводов с приоритизацией проблем, ссылаясь на данные (например, «34% комментариев содержат слово "мало практики"»)	0 — выводы отсутствуют / 5 — выводы обоснованы, конкретны и приоритизированы
1.5	Визуализация (дашборд)	Агент создает все 5 обязательных визуализаций: линейчатая диаграмма, спайдер-график, тепловая карта, столбчатая диаграмма распределения, график тренда	0 — нет ни одной / 5 — все 5 визуализаций выполнены корректно

2. Качественные критерии (глубина и точность анализа)

№	Критерий	Описание	Шкала оценки
2.1	Качество тематического моделирования	Топ-5–7 тем из комментариев релевантны содержанию анкет, не дублируют друг друга и отражают	0 — темы нерелевантны / 5 — темы точны и непротиворечивы

№	Критерий	Описание	Шкала оценки
		реальные проблемы/пожелания слушателей	
2.2	Точность сентимент-анализа	Распределение комментариев на позитивные/нейтральные/негативные соответствует экспертным оценкам (расхождение не более 10%)	0 — расхождение >30% / 5 — расхождение ≤10%
2.3	Глубина группировки предложений	Предложения слушателей сгруппированы по смыслу, указано количество человек, предложивших каждую тему, выделены неактуальные темы	0 — группировка отсутствует / 5 — группировка полная, с частотным анализом
2.4	Качество цитатного ряда	Цитаты репрезентативны (типичные комментарии), указана частота упоминания проблем, цитаты не вырваны из контекста	0 — цитаты отсутствуют / 5 — цитаты с частотами, репрезентативны
2.5	Обоснованность выводов	Каждый вывод в разделе «Траектория изменения программы» имеет числовое или текстовое обоснование (не является голословным)	0 — выводы без обоснований / 5 — каждый вывод обоснован данными

3. Технические критерии (производительность и надежность)

№	Критерий	Описание	Шкала оценки
3.1	Скорость обработки	Время обработки одного потока (15–70 анкет) с выгрузкой всех результатов	0 — >8 часов / 5 — ≤15 минут
3.2	Масштабируемость	Агент одинаково корректно обрабатывает потоки от 15 до 70 слушателей, а также данные за разные периоды	0 — падает/ошибается при >30 слушателях / 5 — работает стабильно при любом количестве в заданном диапазоне
3.3	Стабильность работы	Агент не «падает» при некорректных форматах входных данных (пустые ячейки, нестандартные символы)	0 — падает при любых отклонениях / 5 — обрабатывает некорректные данные с логированием ошибок
3.4	Качество экспорта	Результаты выгружаются в требуемых форматах: Excel (расчеты), Word/PDF (аналитическая справка), HTML (дашборд)	0 — нет ни одного формата / 5 — все форматы корректны и открываются без ошибок

№	Критерий	Описание	Шкала оценки
3.5	Обработка дублей и пропусков	Агент корректно обрабатывает пропущенные ответы и не «сбивается» при наличии пустых полей	0 — не обрабатывает пропуски / 5 — обрабатывает пропуски и дубли, не искажая статистику

4. Пользовательские критерии (удобство и доверие)

№	Критерий	Описание	Шкала оценки
4.1	Удобство запуска	Для запуска агента требуется минимальное количество действий (одна команда или нажатие кнопки, без настройки параметров)	0 — требует сложной настройки / 5 — запуск в 1 клик/команду
4.2	Понятность интерфейса/выводов	Дашборд и аналитическая справка интуитивно понятны для пользователя со средним уровнем цифровой компетенции (Excel + базовые навыки)	0 — не понятны / 5 — понятны без дополнительных пояснений
4.3	Прозрачность логики	Пользователь может проследить, на основе каких данных сформирован тот или иной вывод (ссылки на исходные данные/цитаты)	0 — логика не раскрыта / 5 — каждый вывод сопровождается ссылкой на данные
4.4	Снижение субъективности	Результаты обработки текстов (группировка тем, сентимент) стабильны при повторных запусках (не зависят от случайных факторов)	0 — результаты отличаются при каждом запуске / 5 — результаты стабильны, детерминированы
4.5	Доверие пользователя к результатам	Специалист отдела дизайна образовательных программ и экспертиз доверяет результатам агента и не тратит время на их полную перепроверку (оценка по опросу)	0 — полностью перепроверяет / 5 — доверяет без перепроверки

5. Критерии соответствия бизнес-целям (KPI)

№	Критерий	Описание	Шкала оценки
5.1	Сокращение времени обработки	Время обработки одного потока сокращено с 8 часов до целевого значения	0 — время не сократилось / 5 — ≤ 15 минут
5.2	Полнота охвата комментариев	Обрабатывается 100% текстовых комментариев (против текущих ~60% выборочно)	0 — $< 50\%$ / 5 — 100%
5.3	Сокращение времени от сбора до отправки	Время от сбора анкет до отправки результатов преподавателям/кураторам сокращено с 2–3 дней до 0,5 дня	0 — > 3 дней / 5 — $\leq 0,5$ дня
5.4	Удовлетворенность процессом	Специалисты отдела дизайна образовательных программ и экспертиз оценивают свою удовлетворенность процессом на ≥ 8 из 10 (по опросу)	0 — оценка < 4 / 5 — оценка ≥ 8

Сводная таблица критериев по группам

Группа	Количество критериев	Максимальный балл
Функциональные	5	25
Качественные	5	25
Технические	5	25
Пользовательские	5	25
Бизнес-цели (KPI)	4	20
ИТОГО	24	120

Критерии приемки (пороговые значения)

Уровень	% от максимального балла	Интерпретация
Приемка безусловная	$\geq 85\%$ (≥ 102 баллов)	Агент полностью соответствует требованиям, готов к промышленной эксплуатации
Приемка с доработками	70–84% (84–101 балл)	Агент требует доработки отдельных модулей, но базовая функциональность работает

Уровень	% от максимального балла	Интерпретация
Неприемка	<70% (<84 баллов)	Агент не соответствует требованиям, требуется значительная переработка

Дополнительные критерии для сравнения альтернативных решений

При выборе между несколькими реализациями ИИ-агента рекомендуется дополнительно оценивать:

№	Критерий	Описание
1	Стоимость разработки и владения	Затраты на разработку, обучение модели, хостинг, поддержку
2	Используемые нейросети	Наличие хотя бы одной российской нейросети (требование кейса)
3	Гибкость настройки	Возможность изменения шаблонов отчетов, визуализаций, пороговых значений без перепрограммирования
4	Безопасность данных	Обработка обезличенных данных без передачи на внешние серверы (если не разрешено)